

Azeroth’s Oracle: um Sistema Especialista com Grafo de Conhecimento e GraphRAG para Progressão em World of Warcraft Classic Era

Miguel A. A. Lisboa¹, Luis H. F. de Carvalho¹, Nathan M. Nóbrega¹

¹Centro de Informática, Universidade Federal da Paraíba (UFPB)
Av. dos Escoteiros, s/n, Mangabeira
58058-600, João Pessoa, PB, Brazil

{miguel.lisboa, luis.carvalho, nathan.meira}@academico.ufpb.br

Abstract. *This paper presents Azeroth’s Oracle, an expert system for natural-language questions about quest progression in Elwynn Forest, a controlled slice of World of Warcraft Classic Era. Its Memgraph property graph contains 41 nodes and 60 relationships derived from curated sources and audited Blizzard Game Data API records. A GraphRAG pipeline identifies intent and entities, retrieves facts and paths through read-only Cypher, and grounds the language model on this context. In 20 questions, Com RAG achieved 75% accuracy, against 35% for Sem RAG, averaged 4.9 sources per answer, and halved median latency. Errors concentrated on global and multi-hop questions, exposing the limits of the fixed intent catalog.*

Resumo. *Este artigo apresenta o Azeroth’s Oracle, um sistema especialista para perguntas sobre progressão de missões em Elwynn Forest, recorte controlado de World of Warcraft Classic Era. Seu grafo de propriedades em Memgraph contém 41 nós e 60 relações obtidos de fontes curadas e registros auditados da Blizzard Game Data API. Um pipeline GraphRAG identifica intenção e entidades, recupera fatos e caminhos por Cypher somente leitura e fundamenta o modelo de linguagem nesse contexto. Em 20 perguntas, Com RAG atingiu 75% de acurácia, contra 35% de Sem RAG, apresentou média de 4,9 fontes por resposta e reduziu pela metade a latência mediana. Os erros concentraram-se em perguntas globais e de múltiplos saltos, evidenciando os limites do catálogo fixo de intenções.*

Palavras-chave: grafo de conhecimento, GraphRAG, sistema especialista, modelos de linguagem, Memgraph, Cypher.

1. Introdução

Modelos de linguagem de grande porte (*Large Language Models*, LLMs) produzem texto fluente, mas podem gerar afirmações plausíveis e incorretas, fenômeno conhecido como alucinação [Ji et al. 2023]. Essa limitação restringe seu uso em domínios que exigem precisão factual. A geração aumentada por recuperação (*Retrieval-Augmented Generation*, RAG) [Lewis et al. 2020] reduz o problema ao condicionar a resposta a evidências externas. O GraphRAG [Edge et al. 2024] amplia essa abordagem ao recuperar entidades, relações e caminhos estruturados.

Este trabalho investiga respostas fundamentadas e auditáveis sobre progressão de missões, domínio em que missões, personagens, itens e regiões formam relações interdependentes. A motivação consiste em fornecer procedência explícita e restringir a LLM para que não invente entidades, relações ou fontes. O recorte corresponde a Elwynn Forest, em *World of Warcraft Classic Era*, escolhido por permitir controle da cobertura e verificação manual dos fatos.

O objetivo é combinar um grafo de conhecimento (*Knowledge Graph*, KG), consultas Cypher somente leitura e uma LLM para síntese. O sistema modela procedência por nó, emprega consultas parametrizadas e fornece à LLM apenas a pergunta e os fatos recuperados. A avaliação compara Com RAG e Sem RAG em 20 perguntas, considerando acurácia, fundamentação e latência. As contribuições centrais são o sistema especialista reprodutível e a análise do efeito da recuperação em grafo sobre as respostas. As seções seguintes apresentam fundamentação, dados, arquitetura, metodologia, resultados e conclusão.

2. Fundamentação Teórica e Trabalhos Relacionados

Sistemas especialistas representam conhecimento explícito e separam a base de conhecimento do mecanismo de inferência [Giarratano and Riley 2005]. Grafos de conhecimento organizam esse conteúdo como entidades e relações nomeadas [Hogan et al. 2021]. Este trabalho adota o modelo de propriedades, no qual nós e arestas possuem pares chave-valor, e utiliza Cypher [Francis et al. 2018] para consultas, filtros e percursos. Essa representação permite associar procedência aos nós e recuperar cadeias de progressão.

LLMs captam regularidades linguísticas, mas não garantem fidelidade factual [Ji et al. 2023]. O RAG [Lewis et al. 2020] associa um recuperador a um gerador, enquanto o GraphRAG [Edge et al. 2024] opera sobre entidades, relações e estruturas de grafo. A recuperação local, contudo, pode falhar em perguntas globais dirigidas ao conjunto inteiro. Diferentemente da proposta de [Edge et al. 2024], que constrói grafos a partir de texto e utiliza resumos de comunidades, este trabalho emprega um grafo curado e um catálogo fixo de consultas Cypher, priorizando rastreabilidade e controle das evidências.

3. Dados e Modelagem do Conhecimento

3.1. Fontes e preparação dos dados

A base de fatos foi estruturada em JSON a partir de curadoria manual, Warcraft Wiki [Warcraft Wiki 2026], Wowhead Classic [Wowhead 2026] e Blizzard Game Data API [Blizzard Entertainment 2026]. Cada nó registra identificador, nome, descrição, fonte, endereço, data de atualização e versão do jogo. Antes da carga, a normalização verifica identificadores únicos, campos obrigatórios e relações com origem e destino válidos.

A API Blizzard é utilizada somente na ingestão, sem consulta durante as perguntas. Seus registros enriquecem entidades previamente mapeadas e são mantidos de forma auditável. Dez itens de *Classic Era* foram considerados, mas somente *Patched Pants* foi materializado. Assim, um nó possui procedência direta da API, enquanto os demais dependem de fontes curadas. Relações de campanha, como responsáveis, locais e pré-requisitos, permanecem manuais devido à cobertura limitada da API.

3.2. Estatísticas do grafo

O grafo contém 41 nós e 60 relações em oito rótulos: Quest (12), Item (10), Character (8), Region (4), Requirement (3), Faction (2), Dungeon (1) e Event (1). Entre dez tipos de aresta, predominam `LOCATED_IN` (18), `GIVES_QUEST` (12) e `REQUIRES` (8). A procedência inclui 28 nós da Warcraft Wiki, 9 do Wowhead Classic, 4 de curadoria interna e 1 da Blizzard API. Os maiores graus pertencem a Elwynn Forest (9), Shipment to Stormwind (8) e Goldshire (7). Sara Timberlain é o único nó isolado.

3.3. Esquema do conhecimento

A Tabela 1 resume as principais classes, relações e fontes do KG. A convenção `(questPosterior) - [:REQUIRES] -> (questAnterior)` representa a progressão. `LOCATED_IN` indica a região inicial, `OBJECTIVE_IN` o destino e `PART_OF` a hierarquia regional. O grafo não se limita a armazenar registros, pois codifica cadeias de missões, personagens responsáveis, itens requeridos ou concedidos e a organização espacial do domínio.

Tabela 1. Esquema do grafo de conhecimento. Faction recebe `MEMBER_OF` e Requirement recebe `REQUIRES_LEVEL`.

Classe	Relações de saída	Relações de entrada	Origem
Quest	REQUIRES, LOCATED_IN, OBJECTIVE_IN, REWARDS, REQUIRES_LEVEL	GIVES_QUEST, REQUIRES, REQUIRED_FOR	Wiki / API
Character	GIVES_QUEST, LOCATED_IN, MEMBER_OF	INVOLVES	Wiki
Item	REQUIRED_FOR	REWARDS	Wowhead / API
Region	PART_OF	LOCATED_IN, OBJECTIVE_IN, PART_OF	Wiki

Para responder “Qual é a sequência de missões até *Report to Thomas*?”, o sistema percorre `REQUIRES` na sequência *Report to Thomas* → *Discover Rolf’s Fate* → *Find the Lost Guards* → *Further Concerns* → *A Fishy Peril* e inverte o caminho na resposta.

4. Arquitetura e Implementação

O sistema foi implementado em Python 3.11 ou superior. A pilha utiliza Memgraph com MAGE [Memgraph 2026], acessado pelo protocolo Bolt, uma biblioteca HTTP com autenticação OAuth para ingestão da API Blizzard [Blizzard Entertainment 2026] e a API Gemini [Google 2026] para síntese opcional das respostas. Testes automatizados verificam componentes independentes do banco. A Figura 1 separa a ingestão prévia da rota de consulta.




Figura 1. Arquitetura do Azeroth's Oracle.

4.1. Fluxo de execução

O sistema normaliza a pergunta, identifica uma possível entidade e classifica a intenção em seis categorias: responsável por missão, cadeia de missões, próxima missão, origem de item, localização e vizinhança. A entidade é resolvida por correspondência textual e, quando necessário, por similaridade de caracteres. A intenção seleciona uma consulta Cypher parametrizada, validada antes da execução para bloquear operações de alteração.

A consulta retorna fatos, caminhos e endereços de procedência. A LLM recebe apenas a pergunta e esse contexto, acompanhados de instrução para não empregar conhecimento externo e apresentar a fundamentação. Sem acesso ao modelo, uma resposta determinística expõe os fatos ou declara evidência insuficiente. Essa separação constitui a decisão arquitetural central: o grafo fornece o contexto e a LLM atua apenas na síntese linguística.

5. Metodologia de Avaliação

A avaliação compara a mesma LLM em 20 perguntas. Com RAG recebe fatos recuperados do grafo, enquanto Sem RAG utiliza apenas conhecimento paramétrico. O conjunto inclui seis perguntas localizadas, cinco de múltiplos saltos, quatro de agregação, três globais e duas adversariais. Cada pergunta foi executada nas duas configurações, totalizando 40 respostas registradas com categoria, latência, correção e número de fontes.

A acurácia é definida por $acc = \frac{1}{N} \sum_i c_i$, com $c_i \in \{0, 1\}$. A taxa de respostas fundamentadas corresponde a $\frac{1}{N} \sum_i \mathbf{1}[s_i > 0]$, em que s_i é o número de fontes. A latência é apresentada por média, mediana e desvio-padrão. O conjunto de resultados não inclui uma descrição formal do procedimento de rotulagem, o que constitui ameaça à validade.

6. Resultados e Discussão

6.1. Resultados quantitativos

A Tabela 2 mostra 75% de acurácia para Com RAG, com 15 acertos, e 35% para Sem RAG, com 7. Com RAG apresenta média de 4,9 fontes por resposta, enquanto Sem RAG não apresenta fontes. A mediana de latência cai de 11,85 s para 5,90 s, redução de 50,2%, e a média passa de 18,63 s para 8,11 s. O contexto conciso recuperado do grafo favorece respostas mais breves e reduz a produção de conteúdo especulativo.

Tabela 2. Resultados agregados por configuração, com $N = 20$ em cada condição.

	Acurácia	Fundamentadas	Latência média (s)	Latência mediana (s)	Média de fontes
Com RAG	0,75 (15/20)	19/20	8,11	5,90	4,90
Sem RAG	0,35 (7/20)	0/20	18,63	11,85	0,00

A Figura 2 mostra os maiores ganhos nas perguntas localizadas (100% contra 66,7%), de agregação (100% contra 25%) e de múltiplos saltos (60% contra 0%). Nas adversariais, ambas atingem 100%, mas por mecanismos distintos: Com RAG produz recusa fundamentada, enquanto Sem RAG responde sem procedência. Nas perguntas globais, ambas obtêm 0%.




Figura 2. Acurácia por categoria de pergunta nas configurações Com RAG e Sem RAG.

6.2. Análise de erros

Os cinco erros de Com RAG decorrem principalmente do catálogo fixo. Em duas perguntas de múltiplos saltos, a recuperação não alcança a relação necessária. Na questão sobre a facção de quem entrega *Find the Lost Guards*, a expansão termina no personagem e não percorre a relação seguinte. Na questão sobre quem entrega a missão que recompensa *Patched Pants*, a classificação prioriza a relação missão-responsável, embora a entidade identificada seja um item. Em ambos os casos, a combinação entre classificação por regras e expansão centrada em uma entidade limita a recuperação.

As três perguntas globais falham porque o catálogo não inclui uma consulta de enumeração do grafo inteiro, limitação coerente com [Edge et al. 2024]. Sem RAG, os mesmos casos geram números não sustentados e uma missão inexistente, caracterizando alucinação factual.

7. Conclusão

O *Azeroth's Oracle* fundamenta respostas de uma LLM em um grafo de conhecimento curado, consultado por Cypher somente leitura. Com RAG elevou a acurácia de 35% para 75%, apresentou fontes em 19 das 20 respostas e reduziu pela metade a latência mediana. A análise identificou limitações em perguntas globais e de múltiplos saltos, que excedem o catálogo fixo de intenções. Como trabalhos futuros, propõem-se enumeração global, resolução semântica de entidades, maior cobertura da API e um protocolo de avaliação com múltiplas execuções e métricas adicionais.

Referências

- Blizzard Entertainment (2026). World of warcraft game data apis. <https://develop.battle.net/documentation/world-of-warcraft/game-data-apis>. Acesso em: 6 ago. 2026.
- Edge, D., Trinh, H., Cheng, N., Bradley, J., Chao, A., Mody, A., Truitt, S., and Larson, J. (2024). From local to global: A graph rag approach to query-focused summarization. *arXiv preprint arXiv:2404.16130*.
- Francis, N., Green, A., Guagliardo, P., Libkin, L., Lindaaker, T., Marsault, V., Plantikow, S., Rydberg, M., Selmer, P., and Taylor, A. (2018). Cypher: An evolving query language for property graphs. In *Proceedings of the 2018 International Conference on Management of Data*, pages 1433–1445. ACM.
- Giarratano, J. C. and Riley, G. D. (2005). *Expert Systems: Principles and Programming*. Thomson Course Technology, 4 edition.
- Google (2026). Gemini api documentation. <https://ai.google.dev/gemini-api/docs>. Acesso em: 6 ago. 2026.
- Hogan, A., Blomqvist, E., Cochez, M., d’Amato, C., de Melo, G., Gutiérrez, C., Kirrane, S., Labra Gayo, J. E., Navigli, R., Neumaier, S., Ngomo, A.-C. N., Polleres, A., Rashid, S. M., Rula, A., Schmelzeisen, L., Sequeda, J., Staab, S., and Zimmermann, A. (2021). Knowledge graphs. *ACM Computing Surveys*, 54(4):1–37.
- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y., Chen, D., Dai, W., Chan, H. S., Madotto, A., and Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., and Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474.
- Memgraph (2026). Memgraph documentation. <https://memgraph.com/docs/>. Acesso em: 6 ago. 2026.
- Warcraft Wiki (2026). Elwynn forest. https://warcraft.wiki.gg/wiki/Elwynn_Forest. Acesso em: 6 ago. 2026.
- Wowhead (2026). Classic world of warcraft database. <https://www.wowhead.com/classic/database>. Acesso em: 6 ago. 2026.